Łukasz Kortals
Paweł Józefczyk
Karolina Kornacka

# Document Intelligence: Klasyfikacja typów dokumentów na zbiorze RVL-CDIP z użyciem CNN i Vision Transformer

# Agenda

- Problem i cel projektu
- Dataset RVL-CDIP
- Pipeline i przygotowanie danych
- Modele i trening
- Wyniki ilościowe i jakościowe
- Wnioski i dalsze kierunki rozwoju

W wielu organizacjach każdego dnia przetwarzane są tysiące dokumentów, takich jak faktury, formularze, raporty czy korespondencja.

Aby dokument mógł zostać dalej przetworzony, najpierw należy **rozpoznać jego typ** i przypisać go do odpowiedniego procesu.

Ponieważ ręczna klasyfikacja jest kosztowna i mało skalowalna, coraz większe znaczenie mają **automatyczne systemy klasyfikacji dokumentów oparte na uczeniu maszynowym**.

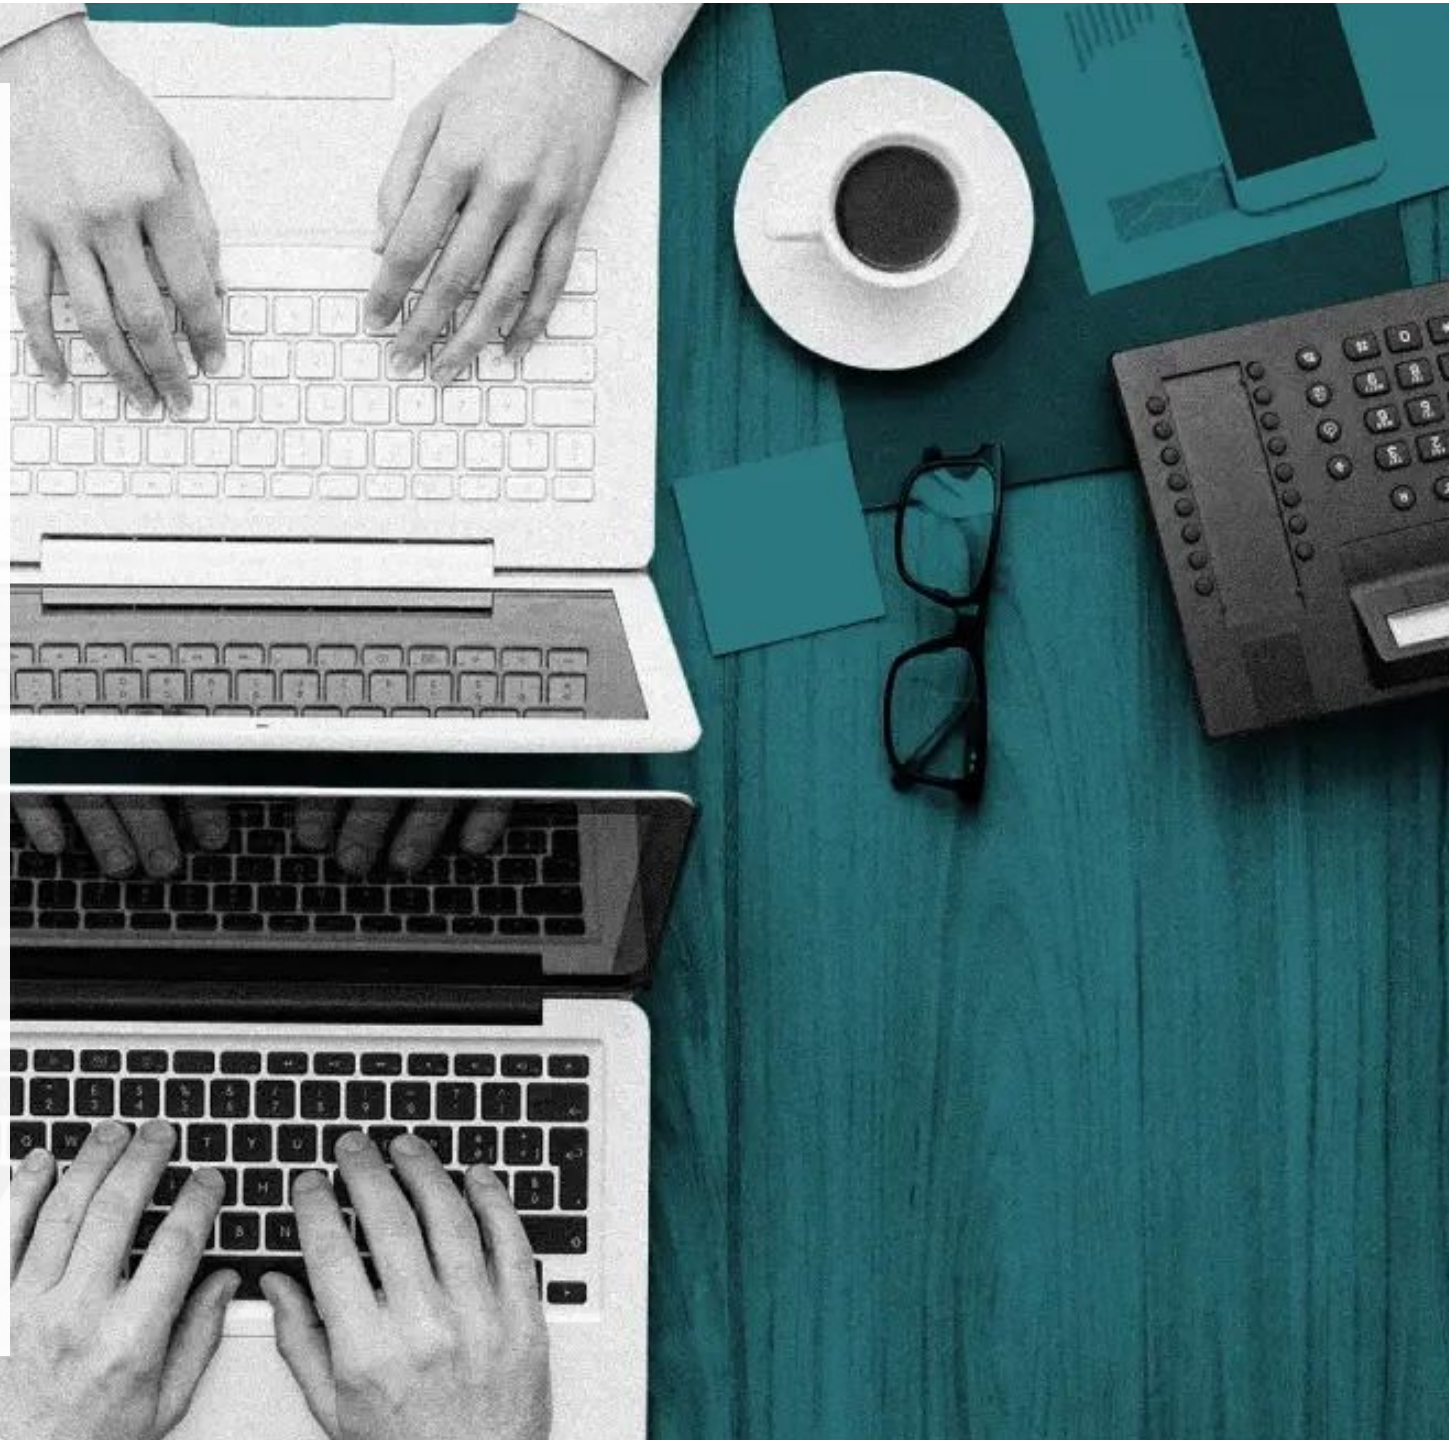

# Cel projektu

- Automatyczna klasyfikacja typu dokumentu
- Podejście **image-only**: bez OCR i bez analizy tekstu
- Porównanie dwóch modeli:

  **CNN** jako baseline

  **Vision Transformer**
- Cel: ocena, czy sam obraz dokumentu wystarcza do skutecznej klasyfikacji

# Dataset

- Dataset: RVL-CDIP
- 16 klas dokumentów
- 400 000 obrazów, 25 000 na klasę
- subset: **800 / 100 / 100 per class**
- razem: **12 800 train / 1 600 val / 1 600 test**
- letter
- invoice
- and others

# Struktura projektu

- data/ — dane surowe i przetworzone
- scripts/ — split i walidacja obrazów
- src/datasets/ — loader danych
- src/models/ — modele CNN i ViT
- src/training/ — trening i ewaluacja
- outputs/checkpoints/ — zapisane modele i wyniki
- notebooks/ — materiały prezentacyjne

# Przygotowanie danych

- utworzenie subsetu i podział na train / val / test
- sprawdzenie poprawności obrazów i wykrywanie uszkodzonych plików
- bezpieczne ładowanie danych odporne na błędne obrazy
- preprocessing:
  - resize do 224 × 224
  - konwersja do RGB
  - zamiana na tensor
  - normalizacja
- augmentacja dla zbioru treningowego:
  - ColorJitter
  - RandomRotation

# Pipeline treningu

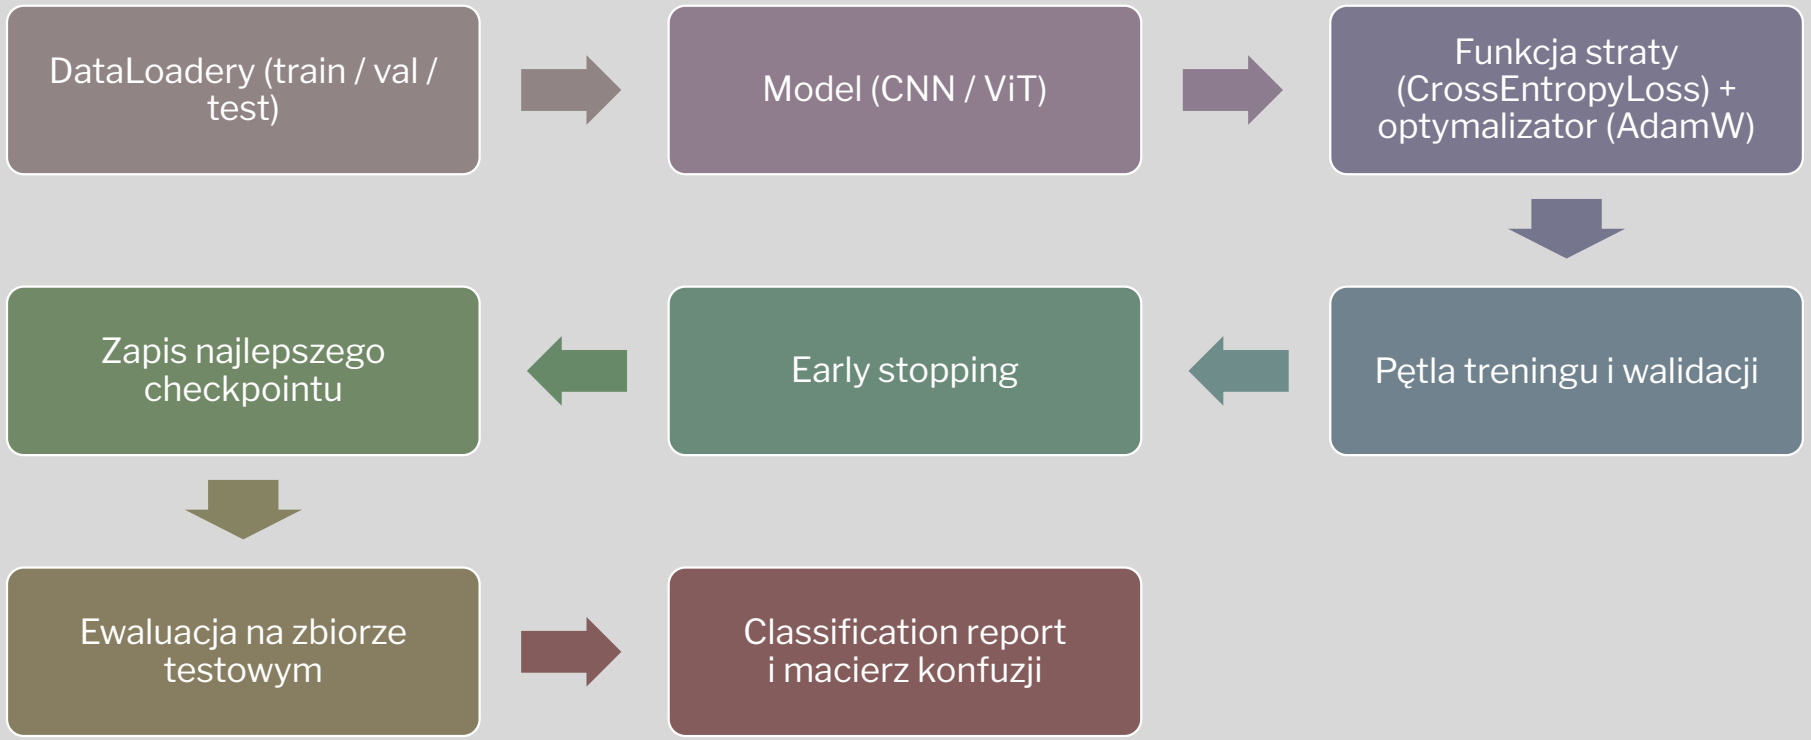

# Porównanie modeli: CNN vs Vision Transformer

**CNN**

- model bazowy (**baseline**) do klasyfikacji obrazów dokumentów
- prosty model konwolucyjny zbudowany w **PyTorch**
- **4 warstwy konwolucyjne**
- ReLU, MaxPool, Adaptive Average Pooling
- prosty klasyfikator **MLP**
- trening **od zera**, bez pretrained weights
- punkt odniesienia do porównania z ViT

**ViT-B/16**

- **Vision Transformer** do klasyfikacji obrazów dokumentów
- model oparty na architekturze **transformerowej**
- użyty w wersji **pretrained**
- następnie **fine-tuning** na zbiorze RVL-CDIP
- końcowa warstwa dopasowana do **16 klas dokumentów**
- lepsze modelowanie **globalnego układu dokumentu**
- mocniejszy model porównawczy względem CNN

# Konfiguracja treningu

Wspólne ustawienia:

- rozmiar wejścia 224 × 224
- batch size: 64
- weight decay: 0.0001
- num_workers: 8
- seed: 42
- AMP / mixed precision: true
- early stopping: val_acc, patience=3
- Tensor Board logging: tak
- loss function: CrossEntropyLoss
- optimizer: AdamW

**CNN:** model konwolucyjny zbudowany w PyTorch

- epochs: 30
- learning rate: 0.001
- pretrained: nie

**ViT:** model z torchvision, następnie fine-tuning

- epochs: 20
- learning rate: 0.0001
- pretrained: tak

# Przebieg treningu modeli (TensorBoard) - Loss

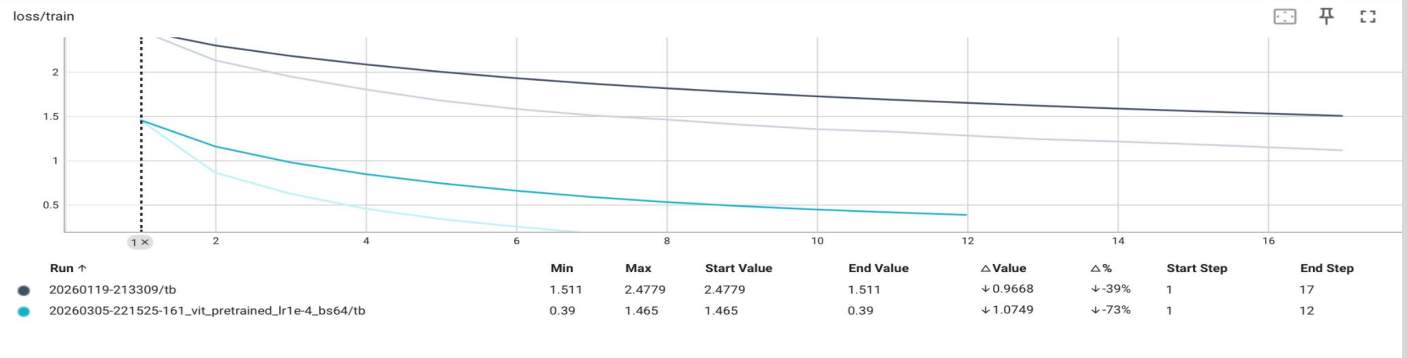


| Run | Min | Max | Start Value | End Value | △Value | △% | Start Step | End Step |
|---|---|---|---|---|---|---|---|---|
| 20260119-213309/tb | 1.511 | 2.4779 | 2.4779 | 1.511 | ↓0.9668 | ↓-39% | 1 | 17 |
| 20260305-221525-161_vit_pretrained_lr1e-4_bs64/tb | 0.39 | 1.465 | 1.465 | 0.39 | ↓1.0749 | ↓-73% | 1 | 12 |

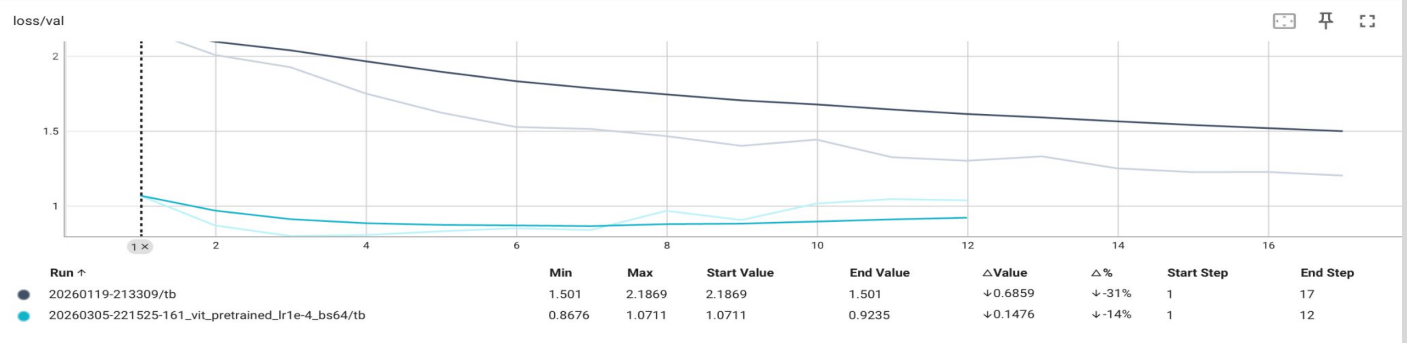


| Run | Min | Max | Start Value | End Value | △Value | △% | Start Step | End Step |
|---|---|---|---|---|---|---|---|---|
| 20260119-213309/tb | 1.501 | 2.1869 | 2.1869 | 1.501 | ↓0.6859 | ↓-31% | 1 | 17 |
| 20260305-221525-161_vit_pretrained_lr1e-4_bs64/tb | 0.8676 | 1.0711 | 1.0711 | 0.9235 | ↓0.1476 | ↓-14% | 1 | 12 |

- ViT szybciej obniżał `train loss` niż CNN
- ViT utrzymywał niższy `val loss`
- CNN uczył się wolniej i kończył z wyższym błędem
- Przebieg `loss` potwierdza przewagę ViT nad baseline CNN

# Przebieg treningu modeli (TensorBoard) - Accuracy

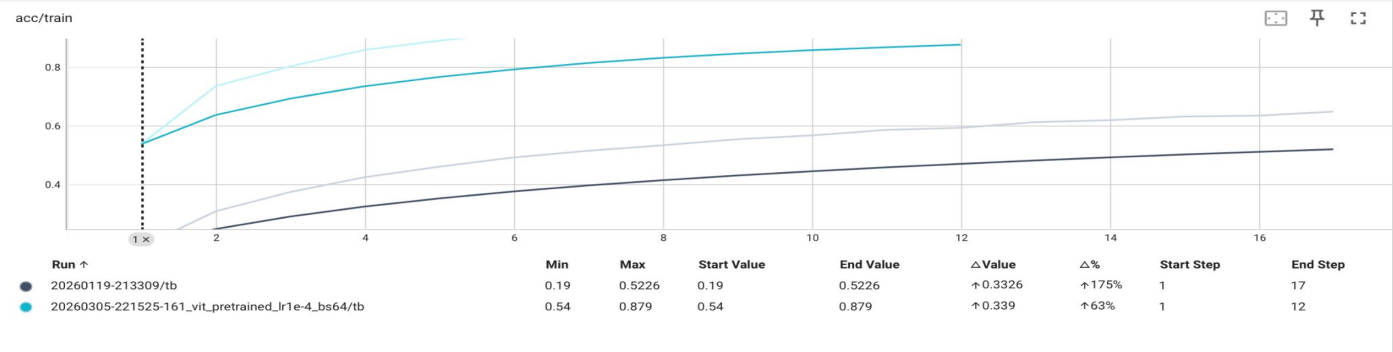


| Run | Min | Max | Start Value | End Value | △Value | △% | Start Step | End Step |
|---|---|---|---|---|---|---|---|---|
| 20260119-213309/tb | 0.19 | 0.5226 | 0.19 | 0.5226 | ↑0.3326 | ↑175% | 1 | 17 |
| 20260305-221525-161_vit_pretrained_lr1e-4_bs64/tb | 0.54 | 0.879 | 0.54 | 0.879 | ↑0.339 | ↑63% | 1 | 12 |

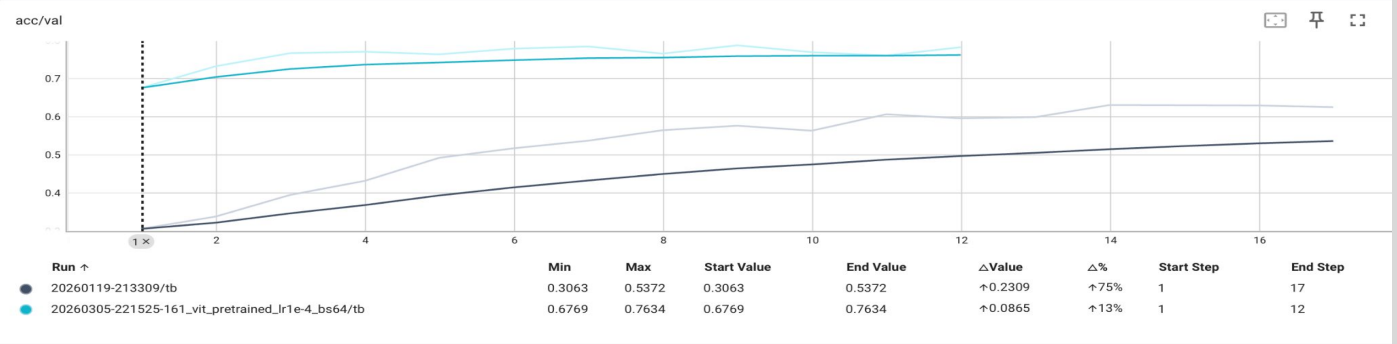


| Run | Min | Max | Start Value | End Value | △Value | △% | Start Step | End Step |
|---|---|---|---|---|---|---|---|---|
| 20260119-213309/tb | 0.3063 | 0.5372 | 0.3063 | 0.5372 | ↑0.2309 | ↑75% | 1 | 17 |
| 20260305-221525-161_vit_pretrained_lr1e-4_bs64/tb | 0.6769 | 0.7634 | 0.6769 | 0.7634 | ↑0.0865 | ↑13% | 1 | 12 |

- ViT osiągał wyższą `train accuracy` i `val accuracy` niż CNN
- ViT uczył się szybciej i wcześniej dochodził do wysokiej skuteczności
- Wyższa `val accuracy` wskazuje na lepszą generalizację modelu ViT
- Trening CNN został zatrzymany na 17 epoce
- Trening ViT został zatrzymany na 12 epoce

# Wyniki

| Klasa | Model | Precision | Recall | F1 |
|---|---|---|---|---|
| **email** | CNN | 0.7982 | 0.8700 | 0.8325 |
| **email** | ViT | 0.9894 | 0.9300 | 0.9588 |
| **invoice** | CNN | 0.4880 | 0.6100 | 0.5422 |
| **invoice** | ViT | 0.7586 | 0.6600 | 0.7059 |
| **scientific_report** | CNN | 0.2738 | 0.2300 | 0.2500 |
| **scientific_report** | ViT | 0.6238 | 0.6300 | 0.6269 |
| **memo** | CNN | 0.3894 | 0.4400 | 0.4131 |
| **memo** | ViT | 0.8137 | 0.8300 | 0.8218 |

ViT był lepszy od CNN nie tylko ogólnie, ale też dla konkretnych klas dokumentów, szczególnie tych trudniejszych do rozróżnienia.

# Wyniki

| Model | Test accuracy | Macro F1 | Invoice F1 |
|---|---|---|---|
| **CNN** | 0.6319 | 0.6283 | 0.5422 |
| **ViT** | 0.7937 | 0.7934 | 0.7059 |

ViT przewyższył CNN we wszystkich głównych metrykach, dlatego został wybrany jako lepszy model do klasyfikacji dokumentów.

# Wyniki jakościowe — Confusion Matrix (ViT)

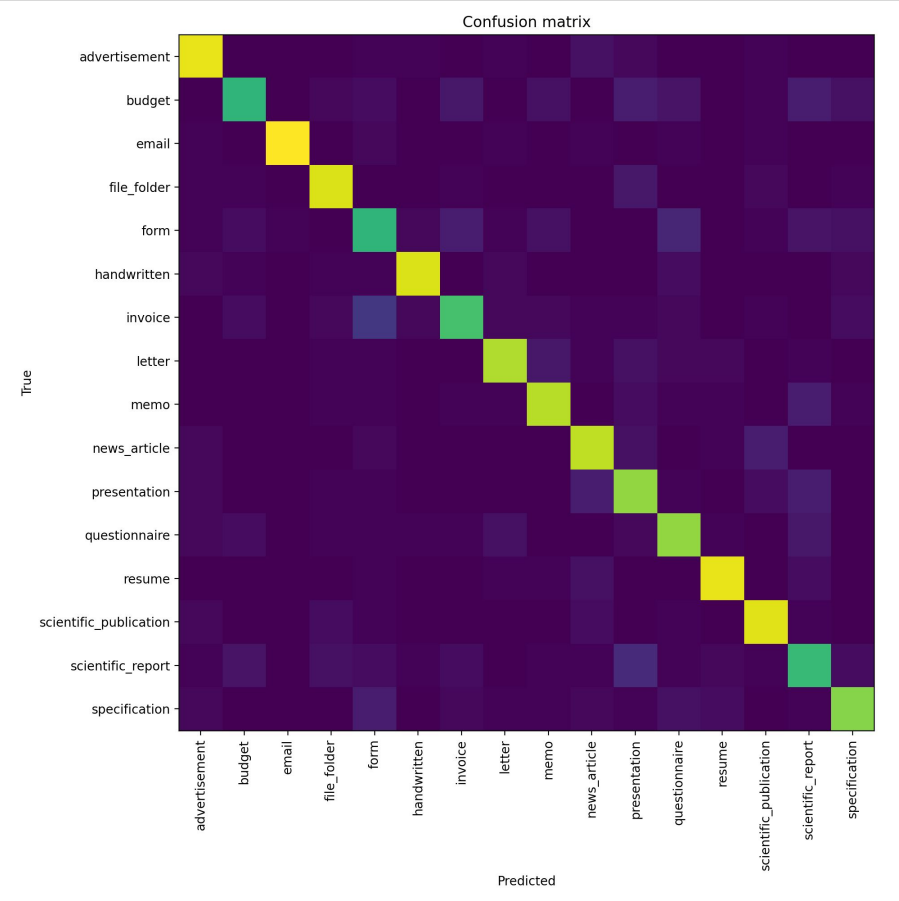


- ViT daje wyraźnie czystszą diagonalę, co oznacza większą liczbę poprawnych klasyfikacji
- Najlepiej rozpoznawane są klasy o bardziej charakterystycznym układzie, np. `email`, `resume`, `handwritten`
- Najwięcej błędów dotyczy klas podobnych layoutem, zwłaszcza dokumentów biurowych i technicznych, takich jak `form`, `invoice`, `budget` i `scientific_report`

# Wnioski

- **Cel projektu został osiągnięty** — sam obraz dokumentu okazał się wystarczający do skutecznej klasyfikacji typu dokumentu
- **CNN** spełnił rolę poprawnego modelu bazowego i potwierdził sens podejścia image-only
- **Vision Transformer** osiągnął najlepsze wyniki i wyraźnie przewyższył CNN we wszystkich głównych metrykach
- Najlepiej rozpoznawane były klasy o bardziej charakterystycznym układzie, np. email, resume, handwritten
- Najtrudniejsze pozostały klasy podobne wizualnie, takie jak form, invoice, budget i scientific_report
- Wyniki pokazują, że **globalny układ dokumentu niesie dużo informacji**, a model ViT lepiej wykorzystuje tę informację niż prosty CNN
- Podejście **image-only** może być użyte jako **pierwszy etap większego systemu Document Intelligence**

# Możliwe rozwinięcia i usprawnienia

**Dodanie OCR** i porównanie podejścia:

- image-only
- text-only
- multimodal

**Trening na większej części RVL-CDIP** lub na pełnym zbiorze danych

**Dalszy tuning hiperparametrów**, np.:

- learning rate
- batch size
- liczba epok / ustawienia early stopping
- augmentacja danych

**Porównanie z dodatkowymi modelami**, np.:

- ResNet
- EfficientNet
- ConvNeXt
- DeiT / Swin Transformer

**Obsługa i klasyfikacja dokumentów wielostronicowych**

**Zastosowanie praktyczne** w systemach automatycznego obiegu dokumentów, sortowania i kierowania do OCR